

# 航空发动机故障诊断技术研究

郑波,朱新宇

(中国民航飞行学院 航空工程学院,四川广汉 618307)



郑波(1984),男,硕士,助教,研究方向为航空电子故障诊断。

收稿日期:2009-08-24

基金项目:国家自然科学基金资助  
(60572185/f01)

**摘要:**介绍了 COMPASS 软件和基于粗糙神经网络模型的新型故障诊断技术。对某航空公司运营中的 ERJ145 飞机双发 AE3007 发动机进行的故障诊断和研究表明,粗糙神经网络模型在故障诊断中的适用性和可信性很强,能够为航空发动机故障诊断提供有效参考。

**关键词:**粗糙集;神经网络;故障诊断;AE3007 发动机;COMPASS

## Investigation of Fault Diagnosis Technology for Aeroengine

ZHENG Bo, ZHU Xin-yu

(Aviation Engineering Institute, Civil Aviation Flight University of China, Guanghan  
618307, Sichuan, China)

**Abstract:** The COMPASS software and a new fault diagnosis technology based on rough neural network model were introduced. The fault diagnosis investigation of twin AE3007 aeroengine of an operating ERJ145 airplane shows that rough neural network has considerable adaptability and reliability in fault diagnosis, and provides effective references for the aeroengine fault diagnosis.

**Key words:** rough set; neural network; fault diagnosis; AE3007 aeroengine; COMPASS

## 1 引言

航空发动机工作条件复杂,维护时技术难度大、成本高,因此,故障诊断的要求很高。科学有效的故障诊断技术,不仅能准确检测发动机故障,保障飞行安全,而且能够节省维修费用,增加航空公司的经济效益。

本文介绍了 COMPASS 软件和基于粗糙神经网络模型的新型故障诊断技术,并对某航空公司的 AE3007 发动机进行了故障诊断。

## 2 AE3007 发动机简介

AE3007 系列发动机是 RR 公司研制的中小推力涡轮风扇发动机,目前,主要用作巴西航空工业公司的 ERJ135/140/145 系列飞机、塞斯纳公司的“奖状”X 以及“全球鹰”高空长航时无人机的动力装置。

该发动机的风扇为 1 级轴流式,宽弦设计;高压压气机为 14 级轴流式;燃烧室采用高耐久性、低污染设计,有 16 个气动雾化喷

嘴,采用双路电容放电点火,火焰筒采用多空散发冷却;涡轮为 2 级轴流式高压涡轮和 3 级轴流式低压涡轮;控制系统采用双通道全余度 FADEC 系统;最大起飞推力为 3370 daN,起飞油耗为 0.34 kg/(daN·h),推重比为 4.72,涵道比为 5,空气流量为 110.2 kg/s,总增压比为 24,最大马赫数为 7.8。

## 3 利用 COMPASS 软件进行故障诊断

COMPASS 软件是 RR 公司开

发的1款专门用于发动机气路性能监控的软件。利用其对AE3007发动机进行故障诊断,主要是将监控到的起飞和巡航阶段相关参数转换成标准状态下的3个参数: $DI_{\pi}$ 、 $DN_2$ 和 $DF_F$ ,它们分别表示发动机的排气温度改变量、高压转子转速改变量和燃油流量改变量、这3个参数均直接引自发动机制造商的使用手册。根据3个参数的变化情况,对照AE3007发动机的性能参数变化(见表1)和巡航参数偏差(如图1所示)进行判断。表1和图1的数据是基于如下所述的典型巡航条件:9144 m,  $Ma=0.8$ , ISA。

表1 AE3007 发动机性能参数变化

	$DI_{\pi}$	$DN_2$	$DF_F$	是否双发
风扇效率(下降)	增大	增大	增大	No
高压压气机效率(下降)	增大	减小	增大	No
高压涡轮效率(下降)	增大	减小	增大	No
低压涡轮效率(下降)	增大	增大	增大	No
引气量增大	增大	增大	增大	No




图1 AE3007 发动机巡航参数偏差

某ERJ145飞机的性能趋势图显示:在某一时刻1发的3个性能参数在巡航时有较大改变,其中 $I_{\pi}$ 约提高90℃,  $F_F$ 约提高12.5%,  $N_2$ 提高约2.1%;只是1发发生变化。根据3个参数的变化情况,查表1可得出风扇、低压涡轮和引气系统可能有故障;此时,还需借助巡航参数偏差图作进一步判断,以确定具体故障。

已知3个参数的变化情况,可得出它们之间的比值 $I_{\pi}:F_F:N_2$

$=1:0.139:0.023$ ,参见图1,飞机引气增加1%的比值是 $1:0.126:0.015$ ,2个比值之间最相似,故判断发生引气故障。

经实际检查,此例中发动机的实际故障是压气机空气流量引气控制活门(CABCV)损坏。更换活门后,该发动机的性能趋势图恢复为正常状态。

上述故障诊断实例表明:对发动机气路性能进行监控,利用COMPASS软件进行数据处理和趋势图绘制,可为诊断发动机气路故障和指示故障位置提供很好的依据,对快速诊断发动机故障可起到重要作用。同时也应看到,该方法没有给出最终结果,需要在分析发动机性能趋势图后才能得到。在下一节中,将利用智能方法处理监控数据,根据样本知识的指示,直接得出诊断结果,而不需要中间的趋势分析过程。

4 利用粗糙神经网络进行故障诊断

4.1 粗糙神经网络故障诊断模型构成

粗糙神经网络模型结构如图2所示。将粗糙集和神经网络融合在一起,该融合模型具有以下优点<sup>[1]</sup>。

(1)应用粗糙集减少条件属性的数量,降低构建神经网络系统的复杂性,同时也减少后继流

程中信息作为网络输入时的特征值计算时间;

(2)应用粗糙集去掉冗余信息,使训练集简化,以减少神经网络训练时间;

(3)使用神经网络作为后置的信息识别系统,该系统有较强的容错及抗干扰能力。

4.2 模型中的创新算法和双输出规则设计

4.2.1 基于SOFM和差别矩阵的离散化方法

SOFM网络的全称为自组织映射神经(Self-Organizing Feature Map)网络。在此离散化算法中,SOFM网络的主要作用是实现连续向量的离散化<sup>[2]</sup>;差别矩阵的主要作用是判断决策表是否存在相对于决策属性的核和决策表是否相容。差别矩阵定义为<sup>[3]</sup>:给定1个决策表 $D_T=(U,C\cup D,V)$ ,其中 $U$ 为论域, $C$ 为条件属性集, $D$ 为决策属性集, $V$ 为属性的值域。 $|U|=n$ ,则定义 $M_{\alpha\alpha}=(c_{ij})_{n\times n}$ 为决策表的差别矩阵,其中

$$c_{ij} = \begin{cases} |\alpha|(\alpha \in C \wedge f_{\alpha}(u_i) \neq f_{\alpha}(u_j)), \\ f_D(u_i) \neq f_D(u_j) \emptyset, \\ f_D(u_i) \neq f_D(u_j) \wedge f_C(u_i) = f_C(u_j) - f_D(u_i) = f_D(u_j) \end{cases}$$

符号“-”表示论域中2个对象的决策值落入决策属性的同1个等价类;空集 $\emptyset$ 表示2个对象所对应的2条决策是不相容的。如果论域中2个对象的决策值不同,同时也存在能够区分这2个对象的条件属性,则所有这样的条件属性组成的集合构成决策表




图2 粗糙集和神经网络融合模型

的差别矩阵的对应元素。

在 1 个相容决策表中, 相对  $D$  核等于差别矩阵中所有只含单个条件属性的元素组成的集合, 即  $C_{ore}(D)=\{\alpha | (\alpha \in C) \wedge (\exists c_{ij} = \{\alpha\})\}$ 。

在研究中发现, 基于差别矩阵的约简算法往往不能实现, 主要原因是矩阵中没有含单个条件属性的元素, 得不到相对  $D$  核, 从而不能求出约简后的属性。这就限制了此算法的应用。

用一般方法离散化后的决策表有可能是不可相容的, 这样的分类显然较粗, 不能正确区分决策值不同的对象。离散化后的决策表即使相容, 在求差别矩阵时, 却得不到只含单个属性的元素, 就不能求出相对  $D$  核, 从而不能对决策表进行约简, 这样的划分显得过细, 不能剔除冗余属性。鉴于此, 基于 SOFM 和差别矩阵的属性离散化算法的思想如图 3 所示。




图 3 离散化算法流程

此算法的步骤如下。

- (1) 利用 SOFM 网络求出决策表的分类, 通常初始划分为 2 类。
- (2) 计算决策表的差别矩阵。

(3) 进行双判断, 若任一判断不通过, 则增加划分数, 返回执行(1); 若通过双判断, 则生成离散化后的决策表, 完成计算。

4.2.2 粗糙集和神经网络双输出规则

粗糙集能利用生成的规则集进行故障诊断, 神经网络能利用其模式识别能力进行故障诊断。若综合利用二者的诊断结果, 则可更最大限度地保证发动机故障诊断结果的准确性和完整性。

设“0”表示发动机无故障状态, “1”表示存在故障状态 1, “2”表示存在故障状态 2, ..., “n”表示存在故障状态 n, 则共有  $n+1$  种状态; 令任意一故障状态为  $i$  或  $j$ , 则最后的输出结果如图 4 所示。

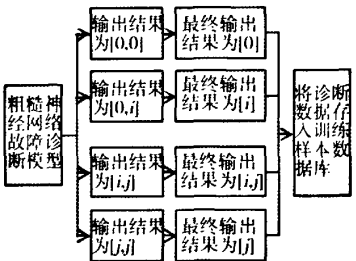


图 4 最终输出结果处理

从图 4 中可看出, 粗糙集和神经网络可能的输出有 4 种情况。当二者输出结果一致时, 诊断结果有 2 种: 0 状态或  $i$  故障, 此时, 诊断结果的准确性较高; 当二者输出结果不同时, 也存在 2 种诊断结果:  $[0\ i]$  和  $[i\ j]$ 。在第 1 种情况下, 设备存在故障, 必须对其进行故障排查; 在第 2 种情况下, 对 2 种故障状态都要进行排查。其目的就是为了将所有可能的安全隐患排除, 以保障设备安全运行, 从而提高故障诊断的可信性和彻底性。

图 4 还指出将诊断数据存入训练样本数据库, 这一点非常有必要。只有拥有完备的训练样本, 才能提高诊断模型的故障识别能力。

4.3 1 次引气故障诊断

4.3.1 样本数据选取

在对某航空公司运营的 ERJ145 飞机的 1 次监控中发现, 其配装的 2 台 AE3007 发动机的 3 个参数有增大的趋势; 在随后的几次监控中发现其增大趋势变缓; 但在 2 天后的监控中, 3 个参数增大速度变快。对完成了飞行任务后的该飞机进行了停飞检查, 通过分析趋势图, 发动机管理中心认定发生了引气故障, 在后来的实际检查中证实了这一判断。进行针对性维修后, 该飞机重新执行飞行任务, 3 个监控参数均恢复到正常水平。

鉴于此, 将这段时间前、后的数据作为训练样本, 且决策属性  $D$  只有 2 种状态: “0”表示 AE3007 发动机工作正常, “1”表示 AE3007 发动机发生引气故障。表 2 列出了 AE3007 发动机训练的样本数据; 是从某一时段巡航监控数据中随机抽取的, 一共 20 组。从巡航报中, 选取马赫数  $Ma$ 、气压高度  $P_A$ 、外界总温  $T_{AT}$ 、油门杆角度  $T_{LA}$ 、燃油流量  $F_F$ 、低压转子转速  $N_1$ 、高压转子转速  $N_2$ 、发动机排气温度  $E_{GT}$ 、压气机出口温度  $T_2$  和压气机出口压力  $P_2$  作为条件属性; 为了检查本文提出的粗糙神经网络的故障诊断能力, 随机抽取 7 组巡航数据作为测试样本, 见表 3。

4.3.2 粗糙集部计算过程

将条件属性划分为 2 类时,

表 2 AE3007 发动机训练样本数据

抽样组	$Ma$	$P_A$	$T_{AT}$	$T_{LA}$	$F_F$	$N_1$	$N_2$	$I_{TT}$	$T_{2-5}$	$P_{2-5}$	$D$
1	0.745	29100	-14.6	68.6	1456	86.26	92.77	724	15	9.7	0
⋮											
20	0.741	26598	8.6	75.3	1640	88.84	96.72	788	40.2	10.6	0

表 3 AE3007 发动机测试样本数据

抽样组	$Ma$	$P_A$	$T_{AT}$	$T_{LA}$	$F_F$	$N_1$	$N_2$	$I_{TT}$	$T_{2-5}$	$P_{2-5}$
a	0.746	27584	1.4	69.6	1640	88.12	96.27	803	31.5	10.3
⋮										
g	0.696	25580	-5.4	64.4	1476	84.7	93.16	711	22.7	10.5

该决策表的核  $C_{or} = \{T_{AT}, F_F, T_{2-5}\}$ , 但存在着含“K”的 2 个元素, 表明该划分明显过粗, 不足以区分决策属性; 将决策属性划分为 3 类时, 核  $C_{or} = \{F_F\}$ , 且不存在不相容元素; 将决策表划分为 4 类时, 差别矩阵不包含核, 使得后续计算无法进行, 说明划分过细。表 4 给出将条件属性划分为 3 类时各个条件属性的离散化区间。

表 4 各属性离散区间

条件属性	分类标示	分类区间
$Ma$	1 类	[0-0.7228)
	3 类	[0.7228-0.7369)
	2 类	[0.7369-+ ∞)
⋮		
$P_{2-5}$	1 类	[0-9.5274)
	2 类	[9.5274-10.5884)
	3 类	[10.5884-+ ∞)

然后, 求出离散化为 3 类后的决策表的约简  $[Ma F_F I_{TT} T_{2-5}]$ ; 连续化属性离散化为 3 类, 不仅能够恰当地识别出决策属性, 同时又能够得到最简约简。所以, 将表 2 离散化为 3 类是合适的。构建决策表的决策矩阵, 建立每个条件等价类的决策函数, 利用合取运算和析取运算, 将决策函数简化为最小析取范式; 其中, 每个合取子式对应 1 条规则。经计算共得 31 条决策规则。

表 5 为得出的规则集和规则参数。其中, 规则参数  $S_0$  表征规则在整个数据中适用的对象数,  $A_c$  表征规则的精度,  $C_0$  表征规则的适用度。至此, 完成了粗糙集部分的计算。

表 5 规则集和规则参数

编号	规则	$S_0$	$A_c$	$C_0$
1	$(F_F, 1) \wedge (I_{TT}, 2) \rightarrow (D, 0)$	2	1	0.181
⋮				
31	$(I_{TT}, 3) \wedge (P_{2-5}, 3) \rightarrow (D, 1)$	1	1	0.111

现在只要将测试样本数据的约简条件属性离散化, 就能对照规则集对 AE3007 发动机进行故障诊断。

4.3.3 神经网络部分计算过程

BP 神经网络应用广泛, 通用性、鲁棒性等都较好, 特别是能够运用在多故障识别中<sup>[4]</sup>, 因此采用 BP 神经网络进行故障识别。

对数据约简前后的网络性能进行比较可知, 约简前后神经网络的网络参数和训练参数都一致, 体现出粗糙神经网络的优越性。

表 6 给出了 2 套神经网络的比较情况, 可看出 Net2 的性能优于 Net1 的。这表明: 经过属性约简后的神经网络简化了网络结构, 减少了网络开销, 加快了收敛速度, 提高了网络性能。

Net1 和 Net2 以及粗糙集的计算结果见表 7。诊断结果表明: 利用约简后的数据训练神经网络, 使网络的容错及抗干扰能力得到显著提高。

表 6 2 套神经网络比较

网络模型	输入层神经元/个	隐含层神经元/个	输出层神经元/个	迭代次数
Net1	10	30	1	77
Net2	4	12	1	23

表 7 诊断结果比较

编号	真实状态	Net1	Net2	RS
		77 次	23 次	
1	0	0.1593	0	0
2	1	0.0074	0.9924	0
3	1	0.7548	0.9975	1
4	1	0.9466	0.9899	1
5	0	0.0053	0	0
6	0	0.0134	0	0
7	0	0	0	0
诊断结果		85.7 %	100 %	85.7 %

4.3.4 分析并输出粗糙神经网络结果

从表 7 中可看出, Net2 的诊断成功率为 100 %, 能够完全辨别出 AE3007 发动机的状态; Net1 和 RS 对测试样本 2 的诊断都出现了错误, 诊断率成功为 85.7 %。综合表 6、7, 可以看出采用粗糙集方法去掉冗余信息后, 不仅提高了网路收敛速度, 降低了网络复杂性, 更重要的是使网络的容错和抗干扰能力增强, 从而增强了网络的实用性和可信性。

但是, 对于样本 2, RS 与 Net2 的诊断结果不一致, 而与 Net1 的一致, 实际检验证明 Net2 的诊断结果是正确的。导致 RS 出错的原因主要是其容错能力和抗干扰能力较差, 对相似性很强样本的识别能力不足; 而导致 Net1 出错的主要原因是知识样本集冗余属 (下转第 30 页)




图 7 实用升限相对于发动机推力变化的敏感性关系曲线




图 8 实用升限相对于发动机推力变化的敏感系数曲线

限的影响更敏感(例如:当推力减小 15 %时,实用升限减小 12.99 %;当推力增大 15 %时,实用升限增大 5.65 %);推力在 -15 % ~ 15 %范围内变化时,这意味着当发动机推力变化 1 %时,实用升限的变化小

于 0.87 %,认为发动机推力变化对实用升限影响不大,但推力减小对使用升限影响更大。

4 结论

(1)发动机推力变化对飞机最小平飞马赫数影响的敏感度很低,对最大爬升率影响的敏感度较高,对最大平飞马赫数及实用升限影响的敏感度由发动机的具体状态和推力变化趋势决定。

(2)对于某一基本飞行性能,在高空飞行时的敏感系数往往要大于低空飞行时的,即在高空飞行时,发动机推力变化对飞机基本飞行性能的影响更为敏感。

(3)对于最小平飞马赫数,ξ随推力的减小而增大,即推力减小时,对最小平飞马赫数的影响较敏感。

(4)对于高空飞行时的最大平飞马赫数,在中间状态下,推力增大时,对最大平飞马赫数的影响较敏感;在最大状态下,推力减小对最大平飞马赫数的影响较敏感。

(5)对于最大爬升率,在所有

高度下,ξ 的值都大于 1,即改变推力 1%时,能够得到大于 1%的最大爬升率的改变;且在最大状态下,高度  $H=15\text{ km}$ ,增大发动机推力时,  $3.76 \leq \xi \leq 4.1$ ,这意味着较小的发动机推力增幅可得到该高度下最大爬升率较大提升。

(6)对于实用升限,推力增大对实用升限的影响较小,推力减小对实用升限的影响较大。

参考文献

[1] Mattingly J D, Heiser W H, Pratt D T. Aircraft engine design [C]. 2nd ed. AIAA Education Series, 2005.  
[2] 张辉, 彭友梅, 汪家芸. 飞机 / 推进系统一体化设计[J]. 燃气涡轮试验与研究, 1996, 2(6): 4-8.  
[3] 陶增元, 王如根. 飞机推进系统总体设计 [M]. 北京: 国防工业出版社, 2002: 116-119.  
[4] Edward J K. A Computer Code for Estimating Installed performance of Aircraft Gas Turbine Engines[R]. NASA /CR-159691, 1979.  
[5] 常振亚. 飞机飞行性能计算手册[M]. 西安: 飞行力学杂志社, 1987.

(上接第 25 页)性较多,冗余属性之间的相似关系干扰了神经网络的学习,从而导致了诊断错误。由此可以看出,有必要对粗糙集和神经网络进行融合和互补。

对 AE3007 发动机的最终诊断结果见表 8。

表 8 粗糙神经网络模型诊断结果							
测试样本	1	2	3	4	5	6	7
真实状态	0	1	1	1	0	0	0
诊断结果	0	1	1	1	0	0	0
诊断率	100 %						

至此,完成了利用粗糙神经

网络对 AE3007 发动机的故障诊断,诊断结果与发动机真实状态完全一致,证明了本文所建立的粗糙神经网络模型可信且实用。

5 结束语

本文建立的用于故障诊断的粗糙神经网络模型,不仅离散化算法思想独特,而且,按照故障诊断准确、彻底的要求所创建的模型结构新颖。实践证明此模型在工程上的适用性和可信性很强,能够为现代工业工程中的故障诊

断提供有效的参考。

参考文献

[1] 安利平. 基于粗糙集理论的多属性决策分析[M]. 北京: 科技出版社, 2008.  
[2] Kohonen T. Self-organization and Associative Memory [M]. Berlin: Springer Verlag, 1982.  
[3] Pawlak Z. Rough Sets [J]. International Journal of Information and Computer Science, 1982(11): 341-356.  
[4] 飞思科技产品研发中心. 神经网络理论与 MATLAB 7 实现[M]. 北京: 电子工业出版社, 2005.